Міністерство освіти та науки України
Харківський національний університет радіоелектроніки
Факультет комп'ютерних наук
Кафедра програмної інженерії

ЗВІТ

з дисципліни «Технології розроблення програмного забезпечення гібридних систем штучного інтелекту»

лабораторна робота №1

РОЗРОБЛЕННЯ RAG-СИСТЕМИ. ПРОЕКТУВАННЯ ПЗ

Виконав:
Студент 1 курсу
гр. ІПЗ-26-2м
Галай А. В.

Перевірив:
ас. PhD Дашенков Д. С.

Харків 2026

Мета та постановка завдання.

Метою лабораторної роботи є набуття практичних навичок попереднього проєктування програмного забезпечення для RAG-системи. У результаті виконання роботи мають бути сформовані такі вміння:

• формулювати компактний сценарій використання ШІ-системи;

• здійснювати свідомий вибір технологічного стеку з простого набору безкоштовних альтернатив;

• будувати спрощену архітектурну діаграму складеної ШІ-системи;

• ініціалізувати робочий простір проєкту у системі контролю версій.

Стислі теоретичні відомості.

Системи, що використовують штучний інтелект, зазвичай є гібридними та включають у себе інші компоненти: ретривери, інтерфейс користувача, сервер, що робить виклики до моделі ШІ і т.п.

Одним із найпоширеніших шаблонів побудови такої системи є RAG. Даний шаблон включає у себе пайплайн прийому даних, сервіс ембедингів, векторний індекс, ретривер, етап генерації та валідатор виходу.

Завдання 1.

Система "Which movie was that?" – це помічник, який допомагає людині згадати назву фільму за описом сюжету, сцени чи окремої деталі із фільму. Користувач описує те, що пам'ятає, своїми словами, а система знаходить фільми, які найкраще підходять під цей опис, і повертає коротку відповідь із назвою, роком випуску та поясненням, чому саме цей фільм підійшов.

Цільовий користувач – звичайна людина, яка колись дивилася фільм і тепер не може згадати його назву. Це може бути студент, що хоче переглянути фільм із дитинства, людина, якій друг переповів сюжет без назви, або просто любитель кіно, якому запам'яталася конкретна сцена. Користувач не є експертом із кіно: він не знає ані режисера, ані акторів, ані року випуску. У нього є лише уривчасті спогади та бажання швидко отримати відповідь.

Запити користувачів зазвичай короткі та неточні. Приклади:

- "Фільм, де хлопчик залишився один на Різдво і захищав дім від грабіжників."
- "Комедія, де чоловік прокидається і щодня проживає один і той самий день."
- "Фільм про корабель, який затонув, і там були Леонардо Ді Капріо та дівчина з намистом."
- "Мультик, де старий прив'язав до будинку кульки й полетів."

Спільне в цих запитах те, що користувач описує не ключові слова з назви, а враження, сцену або сюжетну основу. Саме тому звичайний пошук за ключовими словами тут працює погано і потрібен семантичний пошук по описах фільмів.

Критерії хорошої відповіді

1. Правильний фільм знаходиться у топ-результатах. У кращому випадку на першому місці, у гіршому випадку – у топ-3.

2. Відповідь містить конкретику: назву, рік випуску і одне-два речення пояснення, чому саме цей фільм підходить під опис користувача.

3. Пояснення спирається на опис із бази, а не на вигадані факти. Якщо система каже "у цьому фільмі хлопчик захищає дім на Різдво", то саме це має бути у джерелі, з якого вона відповідала.

4. Відповідь зрозуміла навіть людині, яка не знає жанрової термінології.

Критерії поганої відповіді

1. Правильного фільму немає у видачі взагалі, хоча опис користувача був цілком зрозумілим.

2. Система вигадує неіснуючі фільми або приписує реальним фільмам сюжети, яких у них немає.

3. Видача дуже розмита. Наприклад, у відповідь на запит про "Один вдома" система повертає перелік із десяти різдвяних фільмів без спроби вказати найбільш імовірний.

4. Система не визнає свого незнання. Якщо потрібного фільму немає у корпусі, краще чесно сказати "не знайдено нічого схожого", ніж вигадувати відповідь.

Завдання 2.

Для виконання завдання було обрано датасет Coder-Dragon/wikipedia-movies, що містить більше 30 000 тисяч документів. Розмір датасету можна зменшити взявши лише, наприклад, американські фільми.

Джерело: https://huggingface.co/datasets/Coder-Dragon/wikipedia-movies

Ліцензія: Apache license 2.0

Завдання 3.

Технологічний стек

База даних: PostgreSQL (з розширенням pgvector). У цій базі дані про фільми (рік, жанр, країна) та їхні вектори зберігаються в одній таблиці, тому фільтрувати за роком чи жанром і шукати схожі сюжети можна одним

SQL-запитом. Крім того, це безкоштовна база з відкритим кодом, з якою я вже вмію працювати.

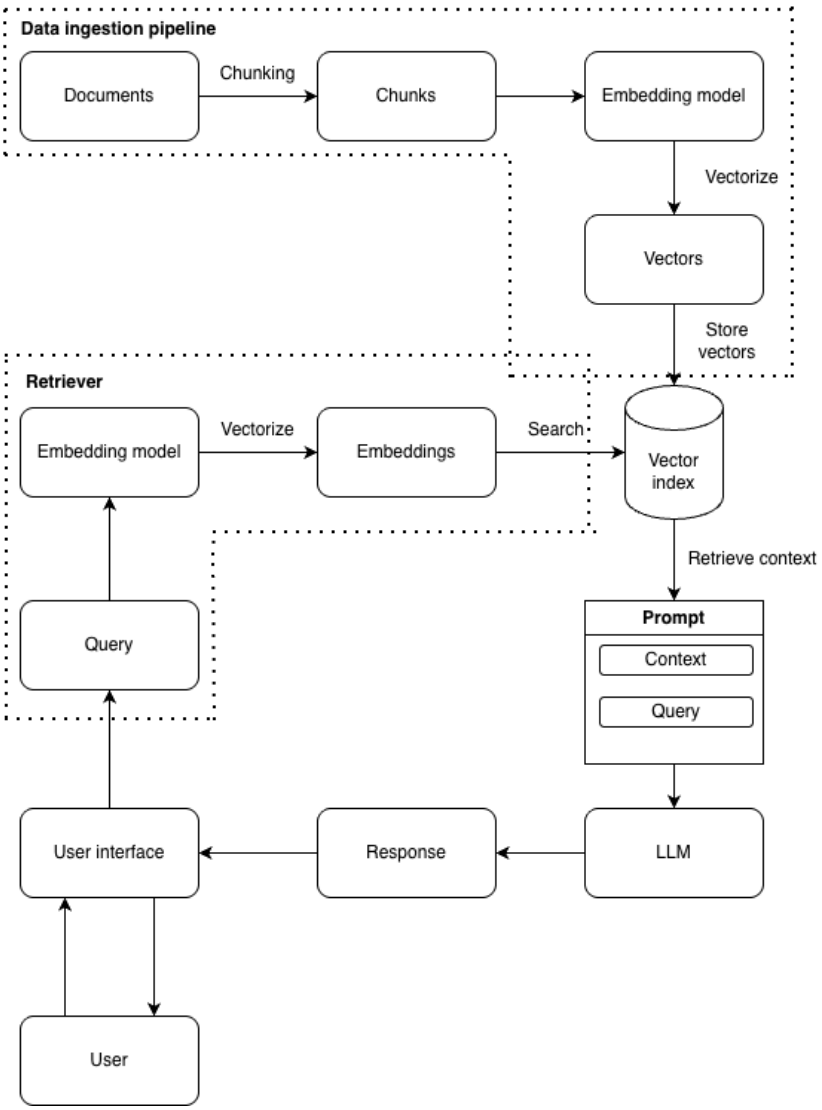
Модель ембедингів: intfloat/multilingual-e5-base**.** Вона розуміє і українську, і англійську, тому знаходить англомовні описи сюжетів за запитами українською. Модель безкоштовна, з відкритим кодом і достатньо легка, щоб швидко працювати на звичайному ноутбуці.

Модель генерації: Qwen3-4B**. Вона перетворює запит користувача на опис сюжету з фільтрами (жанр, роки) і пояснює, чому знайдений фільм підходить, а для таких задач невеликої моделі цілком достатньо. Модель безкоштовна, з відкритим кодом, підтримує українську мову й запускається локально без платних сервісів.**

Мова програмування: Python. Ця мова була обрана через численну кількість бібліотек, що дозволяють із легкістю працювати з AI проєктами.

Завдання 4.

Спрощена контекстна діаграма архітектури системи.



Завдання 5.

https://github.com/andriihalai/which-movie-was-that

Висновок

У ході виконання лабораторної роботи було сформульовано сценарій використання RAG-системи "Which movie was that?", яка допомагає знайти фільм за описом сюжету або сцени фільму. Для реалізації було обрано датасет Coder-Dragon/wikipedia-movies. Технологічний стек: PostgreSQL із розширенням pgvector як векторне сховище, модель multilingual-e5-base для ембедингів, Qwen3-4B для генерації відповідей та Python як основна мова

програмування. Такий вибір дозволяє працювати локально й безкоштовно, а також підтримує українську мову. Було побудовано спрощену архітектурну діаграму, що охоплює пайплайн прийому даних, векторний індекс, ретривер, модель генерації та інтерфейс користувача. Окрім цього, було ініціалізовано Git-репозиторій із базовою структурою каталогів та README-файлом, що містить опис сценарію й посилання на інструкції зі встановлення обраного стеку. Отримані результати формують основу для подальшої реалізації та оцінювання якості системи.

Декларація щодо використання ШІ

Тут і вище використано такий інструмент штучного інтелекту як чат-бот з генеративним штучним інтелектом Claude (Opus 5.5) виключно для коригування та редагування тексту, створеного автором цієї лабораторної роботи, на основі автоматизованої перевірки граматики, структури та стилю, пояснення теоретичних положень.