Міністерство освіти та науки України
Харківський національний університет радіоелектроніки
Факультет комп'ютерних наук
Кафедра програмної інженерії

ЗВІТ

з дисципліни «Технології розроблення програмного забезпечення гібридних систем штучного інтелекту»

лабораторна робота №2

РОЗРОБЛЕННЯ RAG-СИСТЕМИ. ЗБІР ДАНИХ

Виконав:
Студент 1 курсу
гр. ІПЗ-26-2м
Галай А. В.

Перевірив:
ас. PhD Дашенков Д. С.

Харків 2026

Мета

Метою лабораторної роботи є отримання, очищення та підготовка корпусу даних для подальшого індексування у RAG-системі. У результаті виконання роботи мають бути сформовані такі вміння:

• отримувати дані з публічних джерел з документуванням ліцензії та походження;

• реалізовувати простий пайплайн очищення тексту;

• обирати та реалізовувати стратегію чанкування;

• документувати корпус даних у форматі data card.

Постановка завдання

Робочий простір: репозиторій після Лабораторної 1, обраний корпус даних. Форма здачі: очищений, розбитий на чанки корпус у форматі JSONL, код пайплайну на GitHub, data card у reports/lab-2/data-card.md, звіт на DL, Git тег lab-2.

Завдання 1.

Завантажити обраний у Лабораторній 1 набір даних. Розмір робочого корпусу обмежити числом від п'ятисот до десяти тисяч документів — більше не вимагається. У звіті задокументувати: точне джерело та ліцензію.

Завдання 2.

Реалізувати простий пайплайн очищення (рекомендовано, мовою Python), що виконує: нормалізацію кодування у UTF-8; видалення базової HTML-розмітки (можна використати готову бібліотеку beautifulsoup4 або модуль re); фільтрацію документів коротших за 100 символів. Перевірити вручну вміст десяти випадково обраних документів після очищення та зафіксувати спостереження у звіті.

Завдання 3.

Реалізувати чанкування фіксованого розміру (200–500 токенів, можна за словами) з перекриттям 10–20%. Кожен чанк зберігати разом з ідентифікатором документа-джерела, порядковим номером чанка у документі та стабільним глобальним ідентифікатором.

Завдання 4.

Зберегти очищений та розбитий на чанки корпус у форматі JSONL (один JSON-об'єкт на рядок). Закомітити файл у Git, якщо його розмір не перевищує лімітів GitHub; інакше використати Git LFS або зберегти його у зовнішньому сховищі з документуванням посилання.

Завдання 5.

Підготувати коротку data card обсягом одна-дві сторінки у файлі reports/lab-2/data-card.md, що містить: джерело та ліцензію; розмір корпусу до та після очищення; кількість чанків та середній розмір чанка; найчастотніші слова (топ-20); відомі обмеження корпусу.

Стислі теоретичні відомості.

Чанкування – це розбиття документів корпусу даних на менші частини, що мають розмір, який піддається подальшому індексуванню. Сам процес підготовки даних для RAG системи включає в себе також отримання, попередню обробку, чанкування та збереження результатів. Однією із стратегій чанкування є розбиття документів на блоки токен фіксованого розміру, що також можуть мати перекриття сусідніх блоків.

Кожен чанк повинен містити метадані (ідентифікатор документа-джерела, стабільний ідентифікатор чанка), що дозволяють його ідентифікувати серед інших чанків.

Виконання роботи

Для роботи із обраним у попередній лабораторній роботі наробом даних було обрано бібліотеки **pandas** та **datasets**. Для попередньої обробки текстових даних використовувалася відома бібліотека для роботи із природною мовою - **nltk**.

Першим кроком було завантажено оригінальний набір даних, що містить 30671 документів, які описують сюжет кінофільмів та містять метадані (посилання вікіпедію, рік випуску). Оскільки така кількість документів є значно більшою ніж вимагається у завданні лабораторної роботи, набір даних було скорочено. Враховуючи те, що США є країною, де створюється більшість фільмів у світі, було прийнято рішення залишити американські фільми, що були створені після 1950 року і мають опис сюжету більше ніж 100 символів. Таким чином кількість документів вдалося скоротити до 10918 одиниць.

Було реалізовано набір функцій, що виконують видалення html тегів та зайвих символів, нормалізацію кодування тексту та чанкування. Ці функції було використано для очищення тексту опису сюжетів фільму та подальшого розбиття документів на чанки. Було обрано десять випадкових документів для перегляду результатів очищення тексту. Нижче наведено випадково обрані документи. Поле “Plot” є текстом до очищення, а “Plot_clean” – текст після очищення.

[
  {
   "Title": "Tripfall",
    "Plot": "The family of Tom Williams make holidays in California. The family is kidnapped by Eddie, his girlfriend Lonnie and Franklin Ross. They want 1.2 million dollars.",

"Plot_clean": "The family of Tom Williams make holidays in California. The family is kidnapped by Eddie, his girlfriend Lonnie and Franklin Ross. They want 1.2 million dollars."
},
{
"Title": "That Lucky Touch",
"Plot": "An international arms dealer, at a NATO meeting to sell weaponry, becomes entangled with a female journalist from the Washington Post whose worldview is very different to his.",
"Plot_clean": "An international arms dealer, at a NATO meeting to sell weaponry, becomes entangled with a female journalist from the Washington Post whose worldview is very different to his."
},
{
"Title": "El Condor",
"Plot": "Luke, an escaped convict, and Jaroo, a loner gold prospector, team up with a band of Apache Indians in 19th century Mexico to capture a large, heavily armed fortress for the millions—or billions—of dollars in gold that are rumored to be stored within.",
"Plot_clean": "Luke, an escaped convict, and Jaroo, a loner gold prospector, team up with a band of Apache Indians in 19th century Mexico to capture a large, heavily armed fortress for the millions—or billions—of dollars in gold that are rumored to be stored within."
},
{
"Title": "Dead Awake",
"Plot": "Dylan (Stahl) tries to unravel the answer to a decade-long mystery by staging his own funeral and examining who shows up. The problem is, Dylan might actually be dead.",

"Plot_clean": "Dylan (Stahl) tries to unravel the answer to a decade-long mystery by staging his own funeral and examining who shows up. The problem is, Dylan might actually be dead."
},
{
"Title": "Moving Violation",
"Plot": "Drifter Eddie meets shopgirl Cam when he buys an ice cream. Both witness a murder by a local sheriff.",
"Plot_clean": "Drifter Eddie meets shopgirl Cam when he buys an ice cream. Both witness a murder by a local sheriff."
},
{
"Title": "One Is a Lonely Number",
"Plot": "The story follows Aimee Brower (Van Devere), who wakes and finds her husband has left her. After learning everything about why he did it, she then proceeds to put her life back together.",
"Plot_clean": "The story follows Aimee Brower (Van Devere), who wakes and finds her husband has left her. After learning everything about why he did it, she then proceeds to put her life back together."
},
{
"Title": "The Amateur",
"Plot": "When his fiancée is murdered by terrorists, a CIA cryptographer blackmails his superiors into sending him on a field assignment into Czechoslovakia to assassinate those responsible. Once there, however, he discovers a web of deception underneath his fiancée's death.",
"Plot_clean": "When his fiancée is murdered by terrorists, a CIA cryptographer blackmails his superiors into sending him on a field assignment into Czechoslovakia to assassinate those responsible. Once there, however, he discovers a web of deception underneath his fiancée's death."

},
{
"Title": "Checking Out",
"Plot": "Ray Macklin is obsessed with his own mortality. When a close friend suddenly dies of a heart attack at a barbecue, Ray becomes convinced that every ache, pain and twinge he experiences is a sign of his own impending death. His unjustified fears lead him into ever more extensive hypochondria.",
"Plot_clean": "Ray Macklin is obsessed with his own mortality. When a close friend suddenly dies of a heart attack at a barbecue, Ray becomes convinced that every ache, pain and twinge he experiences is a sign of his own impending death. His unjustified fears lead him into ever more extensive hypochondria."
},
{
"Title": "Lost Angels",
"Plot": "Tim Doolan (Horovitz), a troubled youth from a broken home in Los Angeles, is sent to a private psychiatric hospital after an altercation with the police turns violent. In the hospital, he makes a connection with Dr. Charles Loftis (Sutherland), a man with issues of his own.",
"Plot_clean": "Tim Doolan (Horovitz), a troubled youth from a broken home in Los Angeles, is sent to a private psychiatric hospital after an altercation with the police turns violent. In the hospital, he makes a connection with Dr. Charles Loftis (Sutherland), a man with issues of his own."
},
{
"Title": "Puss in Boots",
"Plot": "In this film, Puss transforms from cat to man and when he puts his boots on, he transforms back again.",
"Plot_clean": "In this film, Puss transforms from cat to man and when he puts his boots on, he transforms back again."
}

]

Проглянувши результати очищення можна сказати, що набір даних уже достатньо добре очищений текст. Було також знайдено кілька документів, де пайплайн очищенн тексту видалив посилання на джерела та переноси рядків.

Далі було виконано чанкування документів. Максимальний розмір чанка є 350 токенів (слів) та є перекриття чанків є 15%.

Останнім кроком було підготовлено data card відповідно до вимог лабораторної роботи та збережено data card в репозиторії.

Висновки

У ході виконання лабораторної роботи було побувало пайплайн завантаження, очищення та збереження даних, створено data card для збереженого набору даних. Також було виявлено, що оригінальний набір даних містить текст, що вже є майже повністю очищеним, тому було в даній роботі із оригінального тексту було прибрано лище посилання на джерела та зайві переноси рядків. Створена Data card містить у собі джерело та ліцензію; розмір корпусу до та 17 після очищення; кількість чанків та середній розмір чанка; найчастотніші слова (топ-20); відомі обмеження корпусу. Результати даної роботи будуть використані у наступній для формування векторних представлень даних.

Посилання на репозиторій

https://github.com/andriihalai/which-movie-was-that

Декларація щодо використання ШІ

Тут і вище використано такий інструмент штучного інтелекту як чат-бот з генеративним штучним інтелектом Claude (Opus 5.5) виключно для відлагодження програмного коду програми, коригування та редагування тексту, створеного автором цієї лабораторної роботи, на основі автоматизованої перевірки граматики, структури та стилю, пояснення теоретичних положень.