Міністерство освіти та науки України
Харківський національний університет радіоелектроніки
Факультет комп'ютерних наук
Кафедра програмної інженерії

ЗВІТ

з дисципліни «Технології розроблення програмного забезпечення гібридних систем штучного інтелекту»

лабораторна робота №3

РОЗРОБЛЕННЯ RAG-СИСТЕМИ. ВЕКТОРНІ ПРЕДСТАВЛЕННЯ ДАНИХ

Виконав:
Студент 1 курсу
гр. ІПЗ-26-2м
Галай А. В.

Перевірив:
ас. PhD Дашенков Д. С.

Харків 2026

Мета

Метою лабораторної роботи є побудова векторного індексу над попередньо підготовленим корпусом даних з використанням попередньо навченої моделі ембедингів. Навчання моделей ембедингів у межах лабораторної не передбачено. У результаті виконання роботи мають бути сформовані такі вміння:

- використовувати попередньо навчені моделі ембедингів через бібліотеку sentence-transformers;
- будувати векторний індекс над текстовим корпусом;
- формувати простий набір для оцінювання та вимірювати показник Recall@k;
- здійснювати елементарні експерименти з параметрами індексу.

Стислі теоретичні відомості

Векторне представлення (embedding) перетворює текст у вектор фіксованої розмірності, розміщуючи семантично схожі документи поруч у векторному просторі. Оскільки точний пошук серед мільйонів таких векторів є обчислювально неефективним, для швидкодії використовують індекси наближеного пошуку найближчих сусідів (ANN за допомогою бібліотек Chroma, FAISS або Qdrant). Якість алгоритму оцінюють метрикою Recall@k, яка вказує відсоток запитів, де релевантний документ знаходиться серед перших k результатів.

Виконання роботи

Використано intfloat/e5-small-v2 – компактну англомовну модель з родини E5. Її обрано з двох міркувань: по-перше, корпус і запити англійською мовою, тож спеціалізована модель працює точніше за мультилінгвальний

аналог такого ж розміру; по-друге, модель навчена саме під асиметричний retrieval (окремі префікси query: і passage:), по-друге, вектор у 384 виміри дає швидкий пошук і помірний розмір індексу, що зручно для локального запуску на ноутбуці.

Індекс піднято у Qdrant, в одній колекції movies:

- кількість векторів: 21 892
- розмірність: 384
- метрика оцінювання подібності: cosine similarity
- розмір на диску: близько 109 МБ (каталог storage контейнера Qdrant)

Результати вимірювань. Оцінку проведено на наборі з 22 пар «запит – релевантний чанк» (tests/eval-set.jsonl), результати збережено у tests/eval-results.json. Релевантність оцінювалась на рівні фільму: правильна відповідь зараховувалась, якщо будь-який чанк потрібного фільму потрапив у top-k.

- Recall@5 = 0.77 (17 з 22 запитів)
- Recall@10 = 0.82 (18 з 22 запитів)

Висновки

Побудовано базовий retrieval-пайплайн на основі векторного пошуку в Qdrant з ембедингами intfloat/e5-small-v2. На оцінювальному наборі з 22 запитів система знаходить правильний фільм у топ-5 у 77% випадків і в топ-10 – у 82% випадків. Результати прийнятні для стартової версії, але залишається 18% запитів, де правильна відповідь не потрапляє навіть у топ-10. Основні напрямки для подальшого покращення: гібридний пошук для кращого ранжування запитів з рідкісними іменами та деталями, а також query rewriting через локальну LLM для запитів, що описують фінальні твісти або сцени з середини сюжету.

Посилання на репозиторій

https://github.com/andriihalai/which-movie-was-that/tree/lab-3

Декларація щодо використання інструментів штучного інтелекту

Тут і вище використано такий інструмент штучного інтелекту як чат-бот з генеративним штучним інтелектом Claude (Opus 5.5) виключно для відлагодження програмного коду програми, коригування та редагування тексту, створеного автором цієї лабораторної роботи, на основі автоматизованої перевірки граматики, структури та стилю, пояснення теоретичних положень.